

Relatório Técnico

Features, Pesos e Qualidade de Dados

João Pedro Ferreira Barbosa · 22 de julho de 2026

Projeto de verão. Período coberto: 09/07/2026 a 22/07/2026. Este documento é o registro técnico completo do que foi construído, como cada peça funciona e por que cada escolha foi feita. Ele se aprofunda especialmente nas duas áreas apontadas como decisivas: qualidade de dados e escolha de features (definição exata de cada feature, quantas features existem e seus respectivos pesos).

1 O que é o sistema

O Issuer Opportunity Screener ranqueia emissores corporativos como candidatos à emissão de notas estruturadas (COEs) voltadas ao investidor brasileiro. A premissa comercial, alinhada com a mesa em 13/07/2026: o investidor brasileiro tem pouco apetite por nomes que negociam muito abaixo do Brasil, então todo spread é ancorado no benchmark soberano brasileiro e a régua favorece nomes reconhecíveis com carregamento real.

O sistema parte de um universo editável pela mesa com 125 emissores, busca dados de mercado de crédito para cada um, grava um snapshot imutável, pontua cada nome com um composto documentado e apresenta o resultado como uma tela ranqueada com justificativa em linguagem natural para cada número.

Camada	Responsabilidade
universe.py	Carrega e valida data/universe.csv, os inputs da própria mesa
sources/	Um adaptador por rota de dados: Bloomberg, BQuant, Hermes, fixture
pipeline.py	Orquestra uma coleta: universo, busca, gravação do snapshot
snapshots.py	Snapshots parquet append-only mais um manifesto
scoring.py	O composto, a regra de viabilidade e as flags
validation.py	Estabilidade, sensibilidade a pesos, concentração, co-movimento
insights.py	Movimentações entre snapshots e callouts por regra
reports.py	O artefato de evidência semanal em Markdown
app.py	Dashboard em Streamlit

As dependências fluem estritamente em uma direção, da esquerda para a direita. Nada abaixo de sources/ toca a Bloomberg, então toda a camada de scoring e validação é testável sem um Terminal. São 168 testes automatizados.

2 Catálogo de features

Este é o núcleo da metodologia. São **15 features** (chamadas de sinais no código), agrupadas em **5 blocos**. Cada feature mapeia uma observação bruta de mercado para uma nota de 0 a 100. Uma feature sem dado retorna vazio, não zero, e isso importa: zero é uma afirmação sobre o crédito, ausência é uma afirmação sobre o dado.

Cada banda abaixo é uma escolha deliberada, e todas são constantes em scoring.py que a mesa pode mover.

2.1 Bloco 1: Atratividade de Crédito e Spread (peso 0,35, 5 features)

Este bloco carrega o maior peso porque o spread é a razão de o trade existir. Ele faz a mesma pergunta de cinco formas: esse spread é atrativo em termos absolutos, contra a própria história do nome e contra seus pares.

Feature	Definição e banda
spread_level	$\min(\frac{s}{6}, 100)$, onde s é o spread primário em bps. Atinge 100 em 600 bps e satura ali. Por que 600: acima de aproximadamente 600 bps o nome deixa de ser carregado e passa a ser distress para essa base de clientes. Um nome a 900 bps não é três vezes mais atrativo que um a 300; em geral ele simplesmente não é vendável. A saturação codifica isso. Esta é a banda que mais merece ser desafiada pela mesa.
history_percentile	Percentual dos fechamentos semanais do último ano iguais ou abaixo do spread de hoje, vezes 100. Exige ao menos 12 pontos semanais e é suprimida por completo quando a história está estagnada (ver 5.3). Por quê: responde “esse nome está largo em relação a ele mesmo”, que é a pergunta de valor relativo mais limpa disponível sem um modelo de curva.
vs_1y_ma	$\text{clamp}(50 \cdot \frac{s}{\mu})$, onde μ é a média de 1 ano. Marca 50 quando o nome negocia na própria média e 100 no dobro dela. Por que centrada em 50: negociar na própria média não é nem barato nem caro, então deve ficar no meio da escala e não em um extremo.
vs_1y_p75	$\text{clamp}(100 \cdot \frac{s}{p_{75}})$, onde p_{75} é o percentil 75 de 1 ano. Atinge 100 quando o nome negocia na ponta larga do próprio ano. Por que o percentil 75 e não o máximo: o máximo de um ano de fechamentos semanais costuma ser um único print de estresse, então ancorar nele faria toda semana normal parecer barata.
vs_peer_median	$\text{clamp}(50 + 50 \cdot \frac{s-m}{m})$, onde m é a mediana do spread primário dos outros nomes da mesma cesta. Marca 50 na mediana dos pares e 100 no dobro dela. Exige ao menos 3 pares com spread; caso contrário retorna vazio. Por que o mínimo: uma “mediana” calculada a partir de um único outro papel não é uma mediana, e em cestas rarefeitas isso era efetivamente cara ou coroa entre dois nomes.

2.2 Bloco 2: Qualidade de Crédito e Risco (peso 0,20, 3 features)

Feature	Definição e banda
external_rating	$100 - r \cdot \frac{100}{21}$, onde r é a posição do rating numa escala de 22 níveis (AAA é 0, D é 21). Um notch vale 4,76 pontos. A posição é a mediana entre todos os provedores que resolveram (Moody's, S&P, Fitch, DBRS, KBRA, composto Bloomberg), mapeados para a escala S&P. Por que linear: um notch é um notch, e qualquer convexidade seria uma opinião injustificada sobre probabilidade de default que a régua não tem dado para sustentar.
internal_rating	Mesma fórmula aplicada ao rating interno da mesa em <code>universe.csv</code> . Existe para que o julgamento da mesa entre no score explicitamente, e não como um override aplicado depois.
rating_trend	Perspectiva ou watch positivo marca 75, estável 50, negativo 25, ausente vazio. Por que modesto: uma perspectiva é uma opinião prospectiva, não um fato, então ela inclina o bloco em vez de dominá-lo. Esta feature estava especificada na metodologia original e nunca havia sido implementada; o normalizador de rating estava justamente descartando os marcadores de watch de que ela precisa.

2.3 Bloco 3: Liquidez e Acessibilidade de Mercado (peso 0,20, 3 features)

Feature	Definição e banda
cds_available	100 quando um CDS 5Y resolveu, 0 caso contrário.
cds_liquidity	Um proxy de disponibilidade de cotação, usado como está. Hoje vale 100 sempre que existe cotação, o que na prática o torna uma duplicata de <code>cds_available</code> . É a feature mais fraca do modelo e está nomeada como tal na seção 8.
bond_available	100 quando um bond sênior unsecured elegível foi selecionado, 0 caso contrário.

Este bloco é honesto quanto a ser um proxy. Ele mede se os instrumentos são cotáveis, não quão apertado está o bid-ask nem se há tamanho para negociar.

2.4 Bloco 4: Overlay de Equity (peso 0,10, 3 features)

Feature	Definição e banda
momentum_3m	$\text{clamp}(50 + \Delta_{3m})$, onde Δ é a variação percentual de preço. Estável marca 50; +50% satura em 100. Centrada no zero de variação.
momentum_12m	$\text{clamp}(50 + \frac{\Delta_{12m}}{2})$. A divisão por dois reflete que um ano de variação de preço é cerca de duas vezes mais disperso que um trimestre, então a mesma banda saturaria constantemente.
recommendations	$\text{clamp}(50 + 50 \cdot b)$, onde $b = \frac{\text{compras} - \text{vendas}}{\text{total}}$, limitado a $[-1, 1]$ e portanto mapeado exatamente em 0 a 100 sem corte.

O bloco inteiro é descartado para emissores sem ação listada, em vez de pontuado como zero.

2.5 Bloco 5: Reconhecimento e Aderência ao Cliente (peso 0,15, 1 feature)

recognition é a nota de reconhecimento definida pela mesa em `universe.csv`, numa escala documentada de 0 a 100, usada como está. É o único input puramente julgamental do modelo e carrega 15% do peso. Um proxy medido (media heat) foi conscientemente adiado. A seção 8 propõe uma segunda rodada de pontuação independente para torná-lo defensável.

3 Das features ao ranking

A nota de cada bloco é a **média das features disponíveis**. O composto é a média ponderada das notas dos blocos, **renormalizada sobre os blocos que de fato produziram nota**:

$$S = \frac{\sum_{b \in A} w_b \cdot C_b}{\sum_{b \in A} w_b}$$

onde A é o conjunto de blocos com dado. Tiers: A a partir de 70, B a partir de 50, C abaixo disso.

A renormalização tinha um efeito colateral sério, agora corrigido. Derrubar um bloco não penaliza o nome, apenas remove o que aquele bloco teria dito. Para um nome a 900 bps sem rating, o bloco de Qualidade de Crédito desaparecia e o composto saía em **77,1 (Tier A)**. O mesmo nome com rating CCC+ marcava **65,3 (Tier B)**. A régua estava promovendo sistematicamente justamente o perfil que menos se quer entregar a um cliente: um spread muito largo que ninguém avalia. Um nome sem rating não pode mais alcançar Tier A, e toda linha reporta seu **coverage**, a fração do peso dos blocos que efetivamente pontuou.

4 Os pesos são determinantes?

Os pesos 35/20/20/10/15 são julgamento da mesa. A pergunta honesta é se o ranking é dirigido pela evidência ou por esse julgamento. O `validation.py` responde repontuando todo o universo sob **12 cenários nomeados**: cada um dos cinco pesos de bloco movido para cima e para baixo em 10%, mais uma inclinação combinada pró-spread e outra pró-qualidade. Para cada cenário ele reporta a correlação de ranking contra os pesos documentados e a fração do top 10 que sobrevive.

No universo sintético atual (125 nomes, 104 pontuados):

Medida	Resultado
Cenários	12
Correlação média de ranking vs pesos documentados	0,997
Pior correlação de ranking	0,993 (inclinação pró-qualidade)
Pior sobreposição do top 10	90% (Atratividade de Crédito e Spread -10%)
Nomes que se moveram no pior caso	PEMEX entra, FEMSA sai

Em linguagem direta: em todos os cenários testados, ao menos 9 dos 10 primeiros nomes são os mesmos, e a correlação de ranking nunca cai abaixo de 0,99. Nesses dados, os pesos são uma escolha de apresentação, não a resposta. Quem faz o trabalho é a evidência.

Duas ressalvas ditas de antemão. Primeiro, isso é dado sintético; a rodada precisa ser repetida no universo real antes de o número ser citado como resultado. Segundo, e mais importante, **isso testa os pesos, não as bandas**. Os pontos de saturação da seção 2 (600 bps, o percentil 75, o momentum de 12 meses dividido por dois) não passaram por tratamento equivalente. Sensibilidade a bandas é a próxima peça de validação de maior valor e está nomeada como tal na seção 8.

5 Qualidade de dados

5.1 De onde vêm os dados

Rota	O que fornece	Situação
Bloomberg Desktop API	CDS, bonds, ratings, equity, histórico: tudo	Bloqueada por revisão de entitlement
BQuant	Screen de bonds server-side sob entitlements diferentes	Pronta, rodada de validação pendente
Hermes (interna XP)	Bond EoD por ISIN, proxy de G-spread ancorado no Brasil	Pronta, apenas bonds
Markit	Dados adicionais de crédito	Acesso solicitado
Fixture	Universo sintético determinístico	Usada em testes e demos

O bloqueio da Bloomberg (`responseError LIMIT / WORKFLOW_REVIEW_NEEDED`) é uma decisão de entitlement, não uma falha de código. A superfície de requisição foi minimizada em resposta: campos estáticos para todos os candidatos a bond, campos de pricing apenas para o único bond selecionado por emissor.

5.2 Cobertura é medida, não presumida

Todo manifesto de snapshot registra cobertura por campo. Na rodada sintética atual: CDS 66%, z-spread de bond 83%, ratings 83%, equity 66%. Todo nome que falha em pontuar é listado com o motivo, e todo nome parcialmente coberto carrega `quality_notes` explicando o que falta.

5.3 Defeitos encontrados em rodadas reais, e o que cada um ensinou

Os itens abaixo foram encontrados rodando contra dados reais da Bloomberg e são a razão de várias features terem a forma que têm.

Defeito	Correção e lição
Histórico de preço de bond poluindo o histórico de spread (o caso Xerox +1668 bps)	O <code>PX_LAST</code> de um bond é preço, não spread. O histórico agora usa <code>Z_SPRD_MID</code> para bonds e <code>PX_LAST</code> apenas para CDS. Lição: um nome de campo que funciona para um instrumento pode estar silenciosamente errado para outro.
A busca de instrumentos trazia a curva de CDS para dentro da elegibilidade de bonds	Os papéis são separados antes da elegibilidade, então um contrato de CDS nunca pode ser selecionado como bond.
Ratings só eram requisitados em ações	Ratings agora são consolidados de forma agnóstica a provedor entre bond, depois CDS, depois ação, cobrindo seis provedores.
O caso de borda da viabilidade nunca disparava sem ratings	Passa a usar o rating interno da mesa como fallback.
Seleções de bond em distress ou desatualizadas (o perfil DISH)	Z-spread acima de 1000 bps ou preço abaixo de 50 é sinalizado para revisão em vez de ranqueado silenciosamente.
Históricos de cotação parados lidos como créditos estáveis	Um histórico com menos de 6 fechamentos semanais distintos passa a ser tratado como cotação não atualizada. As features de percentil, média móvel e percentil 75 são suprimidas sobre ele. Antes disso, um nome que ninguém cotava havia meses seria anunciado com confiança como negociando no percentil 100 da própria faixa.

Ratings divergentes colapsavam silenciosamente	Uma discordância de 4 notches entre provedores era mediada para um rating que ninguém publicou. Agora é sinalizada, e o portão de viabilidade lê o provedor mais conservador.
O escritor do universo apagava ISINs	UNIVERSE_FIELDS omitia isin, então adicionar um nome pelo formulário do dashboard apagava silenciosamente todos os ISINs do arquivo, o que teria quebrado a rota Hermes. Corrigido e coberto por teste.

5.4 O sistema de flags

Onze flags anotam um ranking sem alterá-lo. Elas existem porque um número pode estar aritmeticamente correto e ainda assim significar outra coisa.

Flag	Significado
unrated	Sem rating de qualquer provedor ou da mesa: o composto não tem bloco de qualidade de crédito
split_rating	Provedores discordam em 3 notches ou mais; a viabilidade lê o mais fraco
stale_history	Menos de 6 fechamentos semanais distintos: cotação parada, não crédito estável
thin_peers	Menos de 3 pares na cesta com spread, logo sem comparação de mediana
subordinated	Bond abaixo de sênior preferencial: parte do spread é estrutural, não crédito
long_tenor	Bond além de 7 anos contra um padrão de CDS 5Y: parte do ganho é curva
sovereign_correlated	Domiciliado no Brasil ou ligado ao Estado: viável versus Brasil não é diversificação do Brasil
cheap_for_a_reason	Em 450 bps ou mais com perspectiva negativa: largo porque o crédito está deteriorando
benchmark_mismatch	Z-spread de bond medido contra o CDS do Brasil por falta de spread de bond soberano
benchmark_sensitive	O veredito de viabilidade inverte conforme a perna do Brasil usada
small_issue	Abaixo de USD 500mm em circulação: pequeno demais para sustentar um programa de notas

6 A regra de viabilidade

Um nome é viável quando seu spread está igual ou acima do Brasil, ou até 20 bps abaixo do Brasil com rating estritamente mais forte. Três refinamentos tornam a comparação honesta.

Conservador em divergências. O portão lê o rating mais fraco atribuído por qualquer provedor, não a mediana. A mediana pode inventar um rating que ninguém publicou: S&P A e Moody's B1 produzem mediana BBB-, que passa no portão contra o BB do Brasil, enquanto a leitura conservadora B+ não passa. Um portão de risco deve ler pelo lado conservador.

Benchmark comparável. Um emissor precificado pelo CDS 5Y é comparado ao CDS 5Y do Brasil; um emissor precificado por z-spread de bond é comparado ao z-spread do bond de referência do Brasil. Antes, todo emissor era comparado ao CDS soberano independentemente disso, então um nome precificado por bond era medido em bases diferentes. Nomes cujo veredito inverte entre as duas pernas são sinalizados.

Desempate de mediana par. Com um número par de provedores a mediana cai entre dois notches. O arredondamento bancário do Python fazia a direção do desempate depender da posição na escala: A-/BBB+ resolvia para A- (o lado mais forte), enquanto BBB+/BBB resolvia para BBB (o mais fraco). Agora resolve sempre para o lado mais fraco. Uma decisão de metodologia estava sendo tomada por um modo de arredondamento.

7 Validação, reprodutibilidade e movimentações

Estabilidade de ranking. Correlação de Spearman dos compostos entre dois snapshots, mais mudanças de tier, inversões de viabilidade e o movimento médio do composto. Uma régua que se embaralha semana a semana está medindo ruído.

Concentração. HHI e participação do maior balde na shortlist por cesta, país e setor, com alertas acima de HHI 0,30 ou 50% em um único balde. A régua ranqueia nomes um a um, mas o produto é uma cesta: dez nomes Tier A em um só país são a mesma aposta dez vezes. Top 10 atual: HHI de cesta 0,20, HHI de país 0,24 (maior é Brasil com 30%), HHI de setor 0,18.

Co-movimento. Correlação média par a par das variações semanais de spread na shortlist, hoje 0,31 sobre 36 pares. Sobre variações e não níveis, que correlacionariam apenas por tendência.

Movimentações. Inversões de viabilidade são atribuídas entre o emissor e o soberano. O próprio CDS do Brasil rotineiramente se move mais que a tolerância de 20 bps em uma semana, então um nome pode inverter sem que nada tenha acontecido ao crédito. O callout diz qual dos dois se moveu.

Reprodutibilidade. Cada manifesto de snapshot registra o SHA-256 e a contagem de linhas do arquivo de universo que o produziu. O universo é mutável e a quarentena remove nomes, então sem isso um snapshot não pode ser reconstruído e qualquer backtest sobre o histórico teria viés de sobrevivência.

Economia do cliente. `hedged_pickup_bps` subtrai um custo de hedge cambial definido pela mesa do ganho sobre o Brasil, para que o ranking possa ser lido na economia de uma nota com hedge em BRL. O custo é um input, não uma observação de mercado: a régua não tem feed de basis cambial, e fingir o contrário seria o tipo errado de precisão.

8 Limitações conhecidas e decisões em aberto

Estas são declaradas abertamente porque são a fronteira honesta do que o sistema atual sustenta.

1. **Sensibilidade a bandas não foi testada.** A seção 4 valida os pesos. As bandas de saturação da seção 2 não passaram por tratamento equivalente. É o próximo trabalho de maior valor.
2. **`cds_liquidity` é quase vazia.** Na prática duplica `cds_available`. Uma medida real de liquidez precisa de bid-ask ou dados de negociação.
3. **Reconhecimento é julgamento não auditado** carregando 15% do peso. Dois integrantes da mesa pontuando de forma independente e reportando a discordância custaria uma hora e o tornaria defensável.
4. **Um bond por emissor.** Formato de curva e características específicas da emissão (callables, sinking funds) estão fora de escopo, e z-spreads de callables não são comparáveis aos de bullets.
5. **Sem feed de câmbio ou basis cambial.** O custo de hedge é um input da mesa.
6. **`state_linked` precisa de uma passada da mesa** para as estatais da América Latina. Nomes domiciliados no Brasil são detectados automaticamente por `country`.
7. **O entitlement da Bloomberg segue como bloqueio principal** para cobertura completa.

9 Engenharia

168 testes automatizados, todos passando. Uma fonte fixture determinística roda o sistema inteiro sem Terminal, e ela gera deliberadamente os casos incômodos: CDS ausente, ação não listada, histórico parcial, falha de busca, bonds subordinados e longos, e um rating divergente com watch negativo.

Antes da próxima rodada real, o adaptador Bloomberg foi endurecido:

- Os três laços de requisição eram `while True` sem limite sobre `nextEvent`, então uma requisição que nunca recebesse RESPONSE giraria para sempre. Uma rodada de 125 nomes teria travado em silêncio, sem como saber qual requisição morreu. Agora desistem após quatro esperas silenciosas de 30 segundos.
- Uma sessão derrubada é reconectada, em até três tentativas, em vez de fazer todos os emissores restantes falharem com o mesmo erro e desperdiçar a rodada.
- Toda leitura de campo numérico é coagida, então um campo que retorne texto ou array custa um valor e não o emissor inteiro.
- Uma resposta de histórico com `securityError` não levanta mais exceção.
- `IOS_MAX_ISSUERS=3` roda um preflight nos primeiros nomes antes de assumir o universo completo. Recomendado antes de toda rodada longa.

10 Apêndice A: constantes

Constante	Valor	Significado
Pesos dos blocos	35/20/20/10/15	Spread, qualidade, liquidez, equity, reconhecimento
Cortes de tier	70 / 50	Limiares A / B no composto
VIABILITY_TOLERANCE_BPS	20	Quanto abaixo do Brasil um nome mais forte pode negociar
SPLIT_RATING_NOTCHES	3	Discordância entre provedores que conta como divergência
MIN_HISTORY_POINTS	12	Pontos semanais necessários para um percentil
MIN_HISTORY_UNIQUE	6	Fechamentos distintos abaixo dos quais a cotação é lida como parada
MIN_PEERS	3	Pares na cesta necessários para uma mediana
LONG_TENOR_YEARS	7	Prazo do bond além do qual é curva, não crédito
WIDE_SPREAD_BPS	450	Largo o bastante para que perspectiva negativa seja alerta
MIN_ISSUE_SIZE_USD	500mm	Tamanho de emissão necessário para um programa de notas
MOVE_THRESHOLD_BPS	15	Movimento que conta como fechamento ou abertura
OWN_HISTORY_HIGH_PCT	90	Percentil que dispara o callout de faixa própria

11 Apêndice B: variáveis de ambiente

IOS_SOURCE seleciona a rota de dados (bloomberg, bquant, hermes, fixture). IOS_MAX_ISSUERS limita uma rodada de preflight. IOS_LOG_LEVEL=trace imprime cada candidato e decisão de campo. IOS_BOND_CURRENCIES e IOS_TENOR_MIN_YEARS / IOS_TENOR_MAX_YEARS definem a elegibilidade de bonds. IOS_HEDGE_COST_BPS define o custo de hedge cambial. IOS_HERMES_* configuram a rota da API interna. IOS_AUTO_QUARANTINE move nomes não pontuados para fora do universo e está deliberadamente desligada enquanto o acesso a dados não é liberado.